DQN. Отчет

Содержание

1. Обучить Агента решать Acrobot-v1, MountainCar-v0, или LunarLander-v2 (одну на выбор) методом DQN. Найти оптимальные гиперпараметры. Сравнить с алгоритмом Deep Cross-Entropy на графиках.

Выбранная игра: **Acrobot-v1.**
Результаты можно посмотреть в ClearML

Исследуемые гиперпараметры для алгоритма **DQN** в 10 версиях:

- **gamma:** [0.9, 0.99]
- **learning rate:** [0.1, 0.01, 0.001]
- **batch size:** [64, 128, 256]
- **epsilon decrease:** [0.01, 0.001]
- **epsilon min:** [0.1, 0.01, 0.001]

Также было произведено сравнение с алгоритмом **Deep Cross Entropy** (DCEM) с лучшими параметрами для данной игры (см. дз-2):

- **learning rate:** 0.01
- **q params:** 0.6
- **trajectory length:** 500

Общие гиперпараметры для алгоритмов:

- **episode_n (epochs):** 100
- **t_max (максимальное кол-во итераций для одной игры):** 500 (из документации gym)

Reward на итерациях обучения:

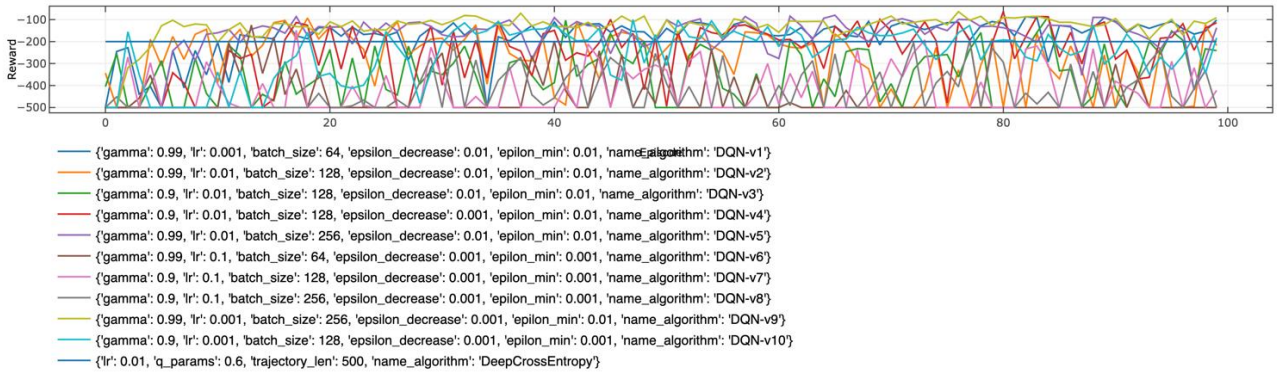

Reward на итерациях обучения (двух лучших DQN и DCEM):

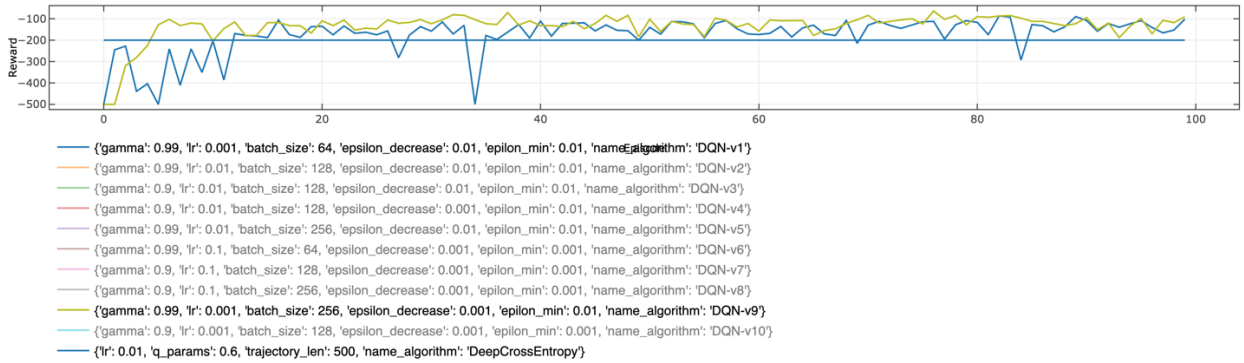

Reward на итерациях обучения для DCEM из дз-2:

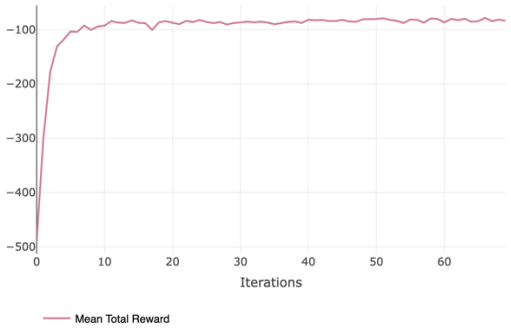

*PS при запуске DCEM почему-то показывал константу на графике, поэтому для него также приведет график из дз-2

Вывод:

Лучший результат DQN достиг при следующих гиперпараметрах:

- **gamma:** 0.99
- **learning rate:** 0.001
- **batch size:** 256
- **epsilon decrease:** 0.001
- **epsilon min:** 0.1

Так как при обучении ведет себя более стабильно без выбросов. Однако на мой взгляд, если сравнивать графики обучения DCEM из ДЗ-2, DCEM показывает более лучшую и быструю сходимость, поэтому для этой задачи можно отдать пальму первенства ему. Возможно, стоило дополнительно настроить Q-function, чтобы результаты DQN стали лучше, чем DCEM, но всё же DQN не сильно уступает DCEM и тоже сходится.

2. Реализовать с сравнить (на выбранной ранее среде) друг с другом и с обычным DQN следующие его модификации:
    - DQN с Hard Target Update;
    - DQN с Soft Target Update;
    - Double DQN.

Выбранная игра: **Acrobot-v1.**
Результаты можно посмотреть в ClearML

Исследуемые гиперпараметры для алгоритма **DQN с Hard Target Update** в 10 версиях:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **q_function_update_epoch (обновляем зафиксированную q-funciton между эпохами):** [None, 1, 10, 50]
- **q_function_update_step (обновляем зафиксированную q-funciton между шагами, то есть может обновиться внутри одной эпохи обучения):** [None, 1, 50, 250]

Исследуемые гиперпараметры для алгоритма **DQN с Soft Target Update** в 10 версиях:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **tau:** [0.01, 0.1, 0.5, 0.9]

Исследуемые гиперпараметры для алгоритма **Double DQN** в 10 версиях:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **tau:** [0.01, 0.1, 0.5, 0.9]

Описанные выше алгоритмы сравнивались с **DQN**:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01

График reward на итерациях обучения:

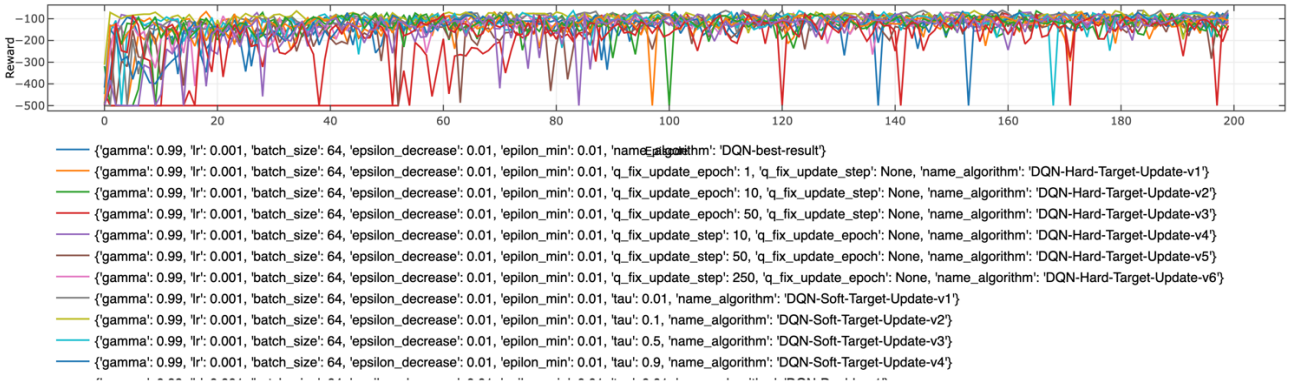

Reward на итерациях обучения (три лучших DQN с Hard Target Update):

Reward на итерациях обучения (два лучших DQN с Soft Target Update):

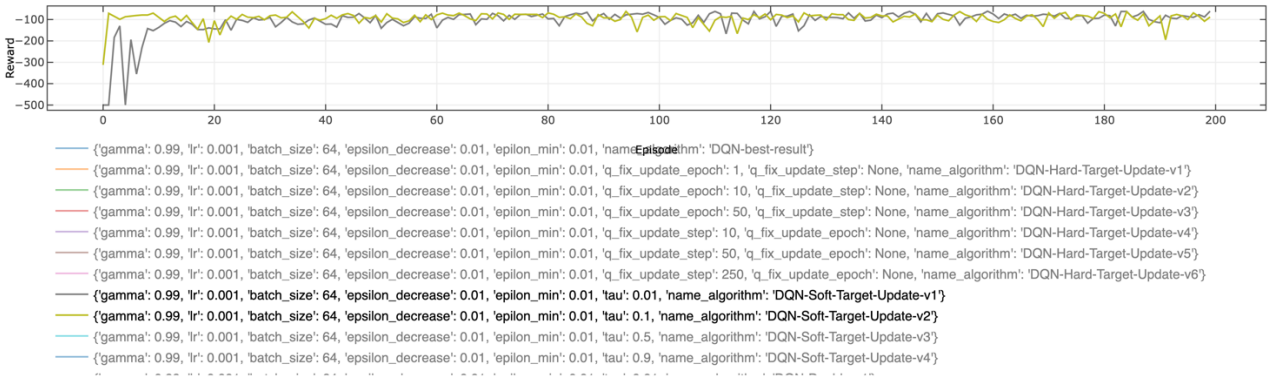

Reward на итерациях обучения (два лучших Double DQN):

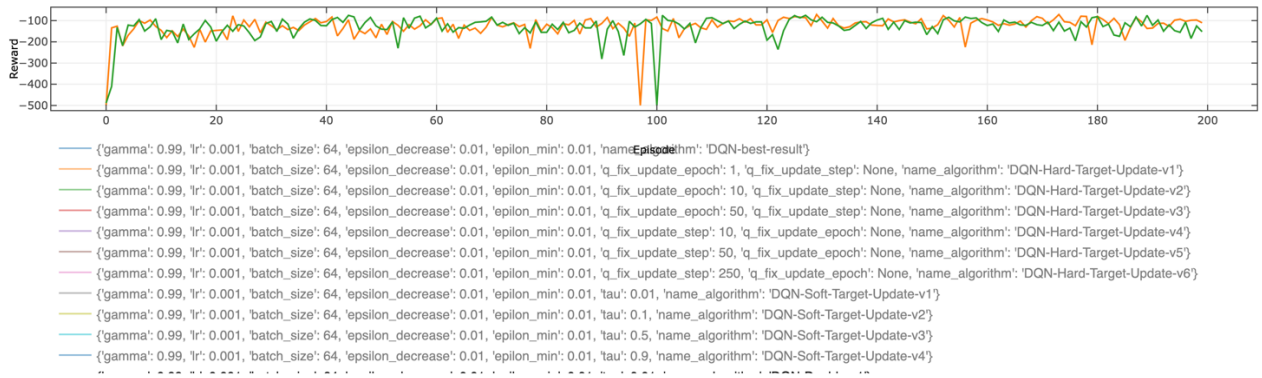

Reward на итерациях обучения (оригинальный DQN и лучшие модификации этого алгоритма):

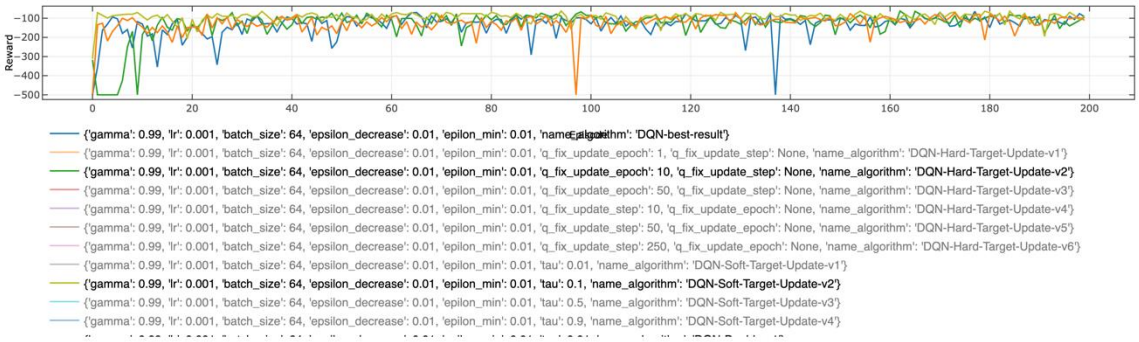

Вывод:
Самые **стабильные результаты и более быструю сходимость** показал алгоритм DQN в модификации **Soft Target Update** с гиперпараметрами:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **tau:** 0.1

DQN в модификации **Hard Target Update** так же показывает лучше результаты, чем обычный DQN. Лучшие гиперпараметры:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **q_function_update_epoch:** 10
- **q_function_update_step:** None

Double DQN в целом показывает лучше результаты, чем обычный DQN, так как ведет себя во время обучения более стабильно, но уступает двум другим модификациям этого алгоритма. Лучшие гиперпараметры:

- **gamma:** 0.99
- **learning rate:** 0.01
- **batch size:** 64
- **epsilon decrease:** 64
- **epsilon min:** 0.01
- **tau:** 0.01

Все модификации показали себя лучше, чем обычный DQN, так как они более стабильные и быстрее сходятся во время обучения.